周报 • 2026-10-17

GitHub 仓库：https://github.com/Cool-11/harness-competitor-eval

一、本周项目进展

• 本周最大的转折，是把评测从“测产品**能不能做**”改成“测它在**哪一步崩**”——对照公告后发现，“专挑执行层弱点去压”才是这次真正要的东西。

• 读了两篇指定的一手文献（Harness-Bench、The Scaffold Effect），试图从原文献中弄明白评测的原理和方向，并据此把失败分类换成有文献依据的版本。

• 据此**重新定义了压测题目集**：把原来“任务完成导向”的题整体重做成一张“**弱点地图**”（7个维度、每维若干题），每题跑测前先写清“要压什么、预期怎么崩”。

• 开始搭建 **badcase 归因方法**：把“给一个失败找归因”这件事拆成可操作的步骤，并用真实失败案例做了试跑，初步能落下来。

• **本周整体处于摸索阶段**——过程里有踩坑和试错，也有方向的转变和经验的吸收。

二、本周难点突破

• **坎一**：要评 Harness，却只能拿五款不同模型去跑 →
用**分层证据**把“模型的锅”和“产品的锅”分开，并在结论里写明边界。

• **坎二**：闭源产品看不见日志和思考过程 →
判分**只认外部看得见的产物**，不给看不见的内部加分。

• **坎三（归因与评分）**：评分要准，但一开始给失败找归因**迟迟找不到头绪** →
后来想明白，一个 badcase
的归因不能一句话概括，**得拆成多个要点逐一定义**（是不是产品的锅 / 坏在哪个环节 / 证据有多硬），评分才有据可依；过程中甚至反过来发现过是自己的判断标准写错了。

三、下周项目计划

1. 把**评测准则定下来**，完善评测流程。
2. **补齐和完善遗留口径**，并做好**日志的合理保存**，方便后续 badcase 的归因。
3. **批量跑压测题目、做变量对照实验**，看改动哪一个变量会影响通过率。
4. 补**裸模型探针基线**（归因第一层，缺它归因不成立）。
5. **结论总结、复盘**，并产出报告。